

Introduction de la Science de données

TP Nettoyage de données

Partie 1

Vous téléchargez le programme *PandasExemples.py* à partir de L'NET. Ensuite vous lancez le programme et donnez votre commentaire étape par étape pour observer des fonctionnements principaux du package **Pandas** de Python.

Partie 2-1

Vous travaillez sur un ensemble de données (*jobs.csv*) qui contient des données sur la réalisation de différents types de travaux sur des appartements et sur des maisons de personnes (réparations, modifications, etc.). Les données existantes contiennent diverses erreurs de différents types. Certaines erreurs sont faciles à repérer, même visuellement (par exemple, avoir des dates dans le mauvais format ou dates et heures à certains endroits et dates seulement à d'autres et ainsi de suite). Sur la base des discussions que nous avons eues en classe, vous devez écrire du code qui trouve et rapporte ces problèmes. Certains des problèmes peuvent être vérifiés pour toutes les colonnes (par exemple, les valeurs manquantes), certains sont spécifiques à une colonne et dépendent du type de données impliquées.

Plus précisément:

- (1) Vérifier les valeurs manquantes : nous devrions vérifier les valeurs NULL ou les chaînes vides. Si le nombre de valeurs NULL dépasse 80 % de toutes les valeurs, la colonne doit être signalée comme « Problématique ».
- (2) Vérifiez le formatage : les colonnes doivent être formatées de manière uniforme, par exemple les dates doit être au format *YYYY-MM-DD* et s'il y a de l'heure en *HH:MM:SS* (c'est juste un exemple). Le point important ici est l'uniformité de la représentation choisie.

Partie 2-2

Vous devez maintenant essayer de corriger certaines de ces erreurs.

- Valeurs manquantes : selon le type de colonne on peut voir différentes solutions, par exemple:

- (i) remplacer la valeur manquante par la moyenne,
- (ii) remplacer les valeurs manquantes par le max ou le min selon les données,
- (iii) remplacer les valeurs manquantes par le mot « NULL »,
- (iv) remplacer par la valeur la plus populaire (celle qui apparaît le plus de fois), etc.

- Format : identifiez le format approprié et transformez toutes les valeurs dans ce format : *YYYY-MM-DD* et s'il y a du temps en *HH:MM:SS*

À la fin de ce processus, vous devez créer une nouvelle table (DataFrame) avec des valeurs et les colonnes qui ont été nettoyées et celles qui restent très problématiques supprimées.

A la fin du TP, vous devez retourner votre compte de rendu à l'ENT.

Dans votre compte de rendu, vous mettez deux programmes Python dans un dossier nommé **VOTRENOM_prénom_DataQuality**. Le premier programme contient le programme *PandasExemples.py* avec vos commentaires. Les travaux sur la partie 2-1 et 2-2 sont intégrés dans le deuxième programme avec des commentaires. N'oubliez pas de mettre le fichier *jobs.csv* et le fichier de sortie final dans votre dossier afin de faciliter l'évaluation de votre travail. Après avoir préparé votre dossier, vous le compressez et soumettez à l'ENT.