

Rapport TP Data Quality

Étudiant : Benchoubane Sid-Ali

Partie 1:

Les commentaires du code sont directement dans le code joint au dossier qui contient ce document

Les quelques erreurs que j'ai résolu sont :

- Les différents renommages des colonnes lors de l'appel de certaines fonctions car on renommé toutes les colonnes en minuscules
- Changement du paramètre pour supprimer les colonnes contenant les valeurs nuls (en précise l'axe et non pas « colonne »)

Partie 2-1:

1-Verification des valeurs manquantes :

Pour cette question j'ai d'abord créé une fonction `is_problematic(column)`, elle prend en entrée une colonne, vérifie ses valeurs et retourne true or false

Ensuite j'ai parcouru toutes les colonnes en appelant cette fonction

Voici l'exécution :

```
sido@Sids-MacBook-Pro Data % /usr/local/bin/python3 /Users/sido/Downloads/Data/Pa
City Owned a plus de 80% de valeurs manquantes
PC Filed a plus de 80% de valeurs manquantes
Mechanical a plus de 80% de valeurs manquantes
Boiler a plus de 80% de valeurs manquantes
Fuel Burning a plus de 80% de valeurs manquantes
Fuel Storage a plus de 80% de valeurs manquantes
Standpipe a plus de 80% de valeurs manquantes
Sprinkler a plus de 80% de valeurs manquantes
Fire Alarm a plus de 80% de valeurs manquantes
Equipment a plus de 80% de valeurs manquantes
Fire Suppression a plus de 80% de valeurs manquantes
Curb Cut a plus de 80% de valeurs manquantes
Horizontal Enlrgmt a plus de 80% de valeurs manquantes
Vertical Enlrgmt a plus de 80% de valeurs manquantes
Zoning Dist2 a plus de 80% de valeurs manquantes
Zoning Dist3 a plus de 80% de valeurs manquantes
Special District 1 a plus de 80% de valeurs manquantes
Special District 2 a plus de 80% de valeurs manquantes
SIGNOFF_DATE a plus de 80% de valeurs manquantes
SPECIAL_ACTION_DATE a plus de 80% de valeurs manquantes
```

2-Pour cette partie la seule solution que j'ai trouvé c'est d'abord trouver les colonnes qui contiennent des dates avec une expression régulière, ensuite les colonnes dates qui ne suivent pas le format voulu (dans ce cas YYYY-MM-DD ou YYYY-MM-DD HH :MM :SS) vont être signalé (dans ce cas toutes les colonnes

dates sont signalé...)

```
Latest Action Date n'est pas une date valide dans le format attendu YYYY-MM-DD HH:MM:SS ou YYYY-MM-DD
Pre- Filing Date n'est pas une date valide dans le format attendu YYYY-MM-DD HH:MM:SS ou YYYY-MM-DD
Paid n'est pas une date valide dans le format attendu YYYY-MM-DD HH:MM:SS ou YYYY-MM-DD
Fully Paid n'est pas une date valide dans le format attendu YYYY-MM-DD HH:MM:SS ou YYYY-MM-DD
DOBRunDate n'est pas une date valide dans le format attendu YYYY-MM-DD HH:MM:SS ou YYYY-MM-DD
```

Partie 2-2 :

Ici j'ai d'abord supprimé les colonnes problématiques sinon après remplissage des valeurs nuls ça sera trop tard, ensuite pour les valeurs numérique j'ai rempli les cases vide par la moyenne, pour les autres cases j'ai rempli par la valeur la plus fréquente. Pour les dates j'ai converti dans le bon format tout en respectant le format 24 heures (5PM = 17h, 12AM = 00h)